第03天 · 接上模型，也保留可重复的基线

从接口和环境变量开始，认识真实工具调用的连接方式。

标准路线：60分钟；忙碌日：20分钟；扩展练习另计。

今天的目标

- 解释模型适配器为何与工具执行分开。

- 运行离线基线并识别其模式。

- 知道如何选学连接Ollama或OpenAI，并记录未验证的部分。

开始之前

- 完成第2课，或能在practice目录运行日课命令。

- 只使用教学材料；修改配置前保留原值，实验结束后恢复或记下修改。

一小时安排

- 15分钟 · 理解概念：阅读四节讲解，记下今天最关键的一个区别；外部资料按指定小节选读。

- 30分钟 · 操作与修改：先完成四步带练，再改变一个参数，保留修改前后的结果。

- 10分钟 · 验收与自测：对照三项验收，完成两道自测并阅读解析。

- 5分钟 · 记录与收尾：写下结果、未解决的问题和下次打开项目后的第一步。

01 · 理解概念

同一个任务，可以有不同决策来源

模型适配器把程序内部请求转成服务商接受的消息格式，再把响应整理成统一结构。离线适配器使用固定规则，可以稳定复现；真实模型根据提示和上下文生成输出，可能提出工具调用，也可能直接回答。二者共享外围工具，但不代表二者的能力相同。

先留下离线基线，再接模型，能帮助定位失败：网络是否可达、模型是否存在、参数是否正确、工具是否拒绝、最终引用是否支持答案。不要把服务连接成功当成整套研究助手已经通过验证。

工具调用是一轮往返，不是执行字符串

真实模型可以提出工具名称和参数，程序随后检查并执行允许的工具，再把工具结果放回下一次模型请求。模型提出调用不等于已经运行工具；只有程序的执行记录才说明发生了什么。

工具结果也应被当成数据。模型不能因为收到一段文本就获得额外权限，程序更不应将它生成的任意字符串作为终端命令。后面的课程会进一步加入参数检查、最大步数、人工批准和来源验证。

Ollama选学：先安装、再检查、再调用

从Ollama官网按自己的系统安装并启动应用；Linux也可遵循官方安装说明。终端执行ollama --version和ollama list确认程序及已下载模型。若服务未运行，可另开终端执行ollama serve；服务已经启动时不需要重复开第二个。

一个可选示例是ollama pull qwen3:4b，然后再次ollama list。官方页面标有工具支持；它只是示例型号，能否流畅运行仍取决于内存、硬件、上下文与服务设置。模型下载和首次启动可单独安排，不计入每天的一小时核心任务。

把费用、凭据和验证范围写清楚

OpenAI路径使用本机环境变量保存API密钥，并选择自己账号可用的模型。请按实践包README设置，不要把密钥放到网页笔记或提交到GitHub。带--allow-network的命令表示你主动选择允许真实服务请求。

课程制作过程中没有替你下载运行大模型，也没有调用你的付费API。连接代码的协议测试与真实推理测试应分别记录。真实调用失败时应明确报错，不应偷偷换回离线结果后继续标成真实模型。

02 · 一步一做

命令在解压后的 practice 文件夹执行。Windows可使用 .\.venv\Scripts\python.exe；macOS/Linux可使用 .venv/bin/python 替代 python。

1. 运行不需要账号的基线

为什么做：把环境、模式和结果先检查清楚。

先用默认offline运行；打开结果中的mode。

```
python run.py day 3
```

预期结果：得到明确的离线教学输出，无需模型下载或密钥。

2. 查看统一问答入口

为什么做：确认任务可以通过独立命令调用。

用下面的英文教学问题运行ask，并阅读实践包README中的provider说明。

```
python run.py ask "What is a tool contract?"
```

预期结果：离线回答与证据或执行记录能够检查；不声称来自真实LLM。

3. 选学准备本地模型

为什么做：把安装与推理分成可定位的步骤。

安装并启动Ollama后执行下面命令；下载时间另外安排。若本机不适合，继续完成离线主线即可。

```
ollama --version
ollama list
ollama pull qwen3:4b
ollama list
```

预期结果：列表出现qwen3:4b；失败时先处理安装、网络或资源问题。

4. 选学进行一次真实请求

为什么做：观察模型提出工具调用与程序执行之间的区别。

在practice目录运行下列命令；保存完整状态，检查mode与工具轨迹。

```
python run.py ask "What is a tool contract?" --provider ollama --model qwen3:4b --allow-network
```

预期结果：服务可用时得到真实请求结果；输出可能与离线不同。若报错，保留错误并按README排查，不伪造成功。

改一改 · 比较任务变化，明确决策来源

- 先执行python run.py ask "What is a tool contract?"并保存结果。

- 再执行python run.py ask "Can correlation prove causation?"，比较命中的资料与回答。

- 若已连接真实模型，再任选同一问题比较provider；未连接时在记录中写“真实模型尚未执行”。

观察什么：问题变化影响检索或回答；离线规则与真实模型仍有明确模式标识。

机制解释：保持任务与工具边界一致，才有条件比较决策来源；连接成功并不等于答案可信。

常见问题

Ollama连接被拒绝

原因：本地服务未启动或服务地址不匹配。

处理：先确认Ollama应用运行；按README检查地址，必要时另开终端运行ollama serve。

提示模型不存在或内存不足

原因：请求的模型未下载，或资源不能支持当前配置。

处理：用ollama list核对名称；选本机能够运行的工具模型并降低资源负担，或继续离线主线。

提示缺少网络许可或API密钥

原因：真实连接需要显式许可和正确环境变量。

处理：只在愿意发起真实请求时使用--allow-network；API设置参照README，密钥保留在本机。

03 · 验收

第3课运行结果、一次参数对照，以及自己能解释的学习笔记。

成果文件：outputs/day03.json

☐ 完成一次离线日课和一次ask调用。

☐ 能描述“模型提出调用→程序检查执行→结果送回模型”的顺序。

☐ 如实记录真实模型已执行或尚未执行，不把连接代码当成推理证据。

自测与解析

1. 模型返回一个工具调用，下一步应是什么？

- A. 直接执行任何生成的代码

- B. 程序校验工具名和参数，再执行允许的工具

- C. 把它当作已经完成的计算

- D. 自动扩大权限直到成功

答案：B。 工具调用是请求，执行权属于外围程序；参数、权限和预算均需要检查。

2. 尚未运行真实模型时，哪种记录准确？

- A. 已完成真实LLM能力验证

- B. 所有模型都能调用本工具

- C. 离线基线已运行，真实模型接入尚未实测

- D. 模型连接必然免费且无资源要求

答案：C。 把完成范围与未执行部分分别登记，便于下次继续验证，也避免夸大作品能力。

小词典

- Provider：提供模型决策或生成服务的实现。

- 适配器：把内部请求与外部服务格式互相转换的组件。

- Tool call：模型提出的工具名称及结构化参数请求。

04 · 我的记录

- 这次失败若发生在服务连接层，我应该先检查什么？

- 哪些信息可以公开，哪些应只留在本机环境变量？

忙碌日：20分钟

- 用3分钟读“同一个任务，可以有不同决策来源”，写下一个关键区别。

- 用12分钟运行 python run.py day 3，打开 outputs/day03.json 并核对第一项预期结果。

- 用5分钟完成第一道自测并写一句解释；完整参数实验和其余验收留待下次。

留下本课运行结果与一句自己的解释；精简完成单独记录，不等于完整课程已经验收。

有余力再做：20分钟选学 · 做一张模型接入记录卡

- 记录provider、模型全名、日期、输入问题和是否触发工具。

- 记录实际延迟、失败情况与尚未验证的能力。

- 以同一个问题比较两次结果，区分格式一致与内容可靠。

参考资料与阅读范围

Ollama 官方：Tool calling：只看单次工具调用及把工具结果送回模型的消息顺序。

https://docs.ollama.com/capabilities/tool-calling

Ollama 模型页：qwen3:4b：核对模型名称与工具支持标签；下载大小不等于完整运行内存需求。

https://ollama.com/library/qwen3:4b

OpenAI 官方：Function calling：阅读工具定义、模型提出调用、程序执行及返回结果的流程。

https://platform.openai.com/docs/guides/function-calling

下一步

下一课检查输出结构：能生成JSON，并不等于结果可以直接采用。