第05天 · 给 Agent 配一组可信的工具

把能做什么、怎么调用和失败后怎么解释写清楚。

标准路线：60分钟；忙碌日：20分钟；扩展练习另计。

今天的目标

- 阅读一个工具的名称、说明、参数和输出。

- 通过错误top_k观察工具边界。

- 理解工具白名单与最小权限。

开始之前

- 完成第4课，或能在practice目录运行日课命令。

- 只使用教学材料；修改配置前保留原值，实验结束后恢复或记下修改。

一小时安排

- 15分钟 · 理解概念：阅读四节讲解，记下今天最关键的一个区别；外部资料按指定小节选读。

- 30分钟 · 操作与修改：先完成四步带练，再改变一个参数，保留修改前后的结果。

- 10分钟 · 验收与自测：对照三项验收，完成两道自测并阅读解析。

- 5分钟 · 记录与收尾：写下结果、未解决的问题和下次打开项目后的第一步。

01 · 理解概念

工具是一个受约束的函数入口

工具将某种动作包装成程序可以执行的接口，例如检索教学资料、读取证据记录或分析指定CSV。一个合格接口应交代输入参数、返回结构、失败状态和允许触及的数据范围。描述过于含糊，会让调用方很难选择正确工具。

从你的科研场景出发，未来可以把CLEAR或MEF等已有流程包装成工具，但包装不会替这些方法补上统计前提。当前课程只使用教学材料与合成数据，不会宣称已经连接或验证那些专业研究流程。

工具说明应帮助正确选择

名称应说明动作，说明文字应写明适合和不适合的任务。search_evidence可用于寻找给定资料中的相关记录；它并不等于搜索全互联网，也不意味着返回内容已经经过全面事实核验。

参数应尽量少而明确。query说明找什么，top_k限制最多返回多少条。路径、字段和算法选项若可任意传入，就会增加误用空间。第一版先支持少量可解释的操作，再根据确实存在的需求扩充。

白名单让执行权留在程序一侧

程序只允许注册过的工具名称，并验证参数后才执行。模型即使提出不存在的工具、额外字段或超范围计数，也应得到清楚的拒绝。不要用eval或任意终端执行把模型文本直接变成权限。

白名单只是其中一层约束。被允许的工具本身仍可能设计有问题，返回的材料也可能包含误导内容。后面会继续学习不可信数据、人工批准和评价，不能把一份白名单理解成安全问题已经全部解决。

失败结果也应有稳定结构

工具失败时应告诉调用者发生在哪一层：参数不符、资料缺失、预算耗尽还是运行错误。将一切失败都转成空列表，会让后续流程误把故障解释为“没有证据”。

本课比较合法调用和主动制造的错误调用。你应能够在输出中找到成功结果与拒绝原因，并说明为什么错误调用没有继续访问工具。保持错误可解释，是后面重试与恢复的基础。

02 · 一步一步做

命令在解压后的 practice 文件夹执行。Windows可使用 .\.venv\Scripts\python.exe；macOS/Linux可使用 .venv/bin/python 替代 python。

1. 运行工具案例

为什么做：观察工具注册与实际执行。

先保留默认配置。

```
python run.py day 5
```

预期结果：看到允许的工具、合法调用结果以及参数边界演示。

2. 读懂一次调用的四个部分

为什么做：把自然语言需求与函数接口对应起来。

打开输出，定位工具名、参数、返回值和失败信息；同时阅读实践代码中的工具定义。

```
python -m json.tool outputs/day05.json
```

预期结果：能解释top_k控制结果数量，不代表证据质量。

3. 改变错误参数

为什么做：看拒绝是否真正发生。

在experiments.json中找到day05.invalid_top_k，设置一个明显超范围的数再运行。

```
python run.py day 5
```

预期结果：非法调用被拒绝，合法调用仍可完成。

4. 写一张科研工具卡

为什么做：将接口方法迁移到熟悉工作。

选择“检查样本表缺失”这样的有限操作，写输入、输出、失败和权限四段说明；本课只写设计，不调用真实研究数据。

预期结果：一张别人能够理解的工具卡，并明确哪些资料可访问。

改一改 · 结果数量与合法范围

- 先记录默认day05.invalid_top_k产生的错误。

- 将它改成0，再改成一个明显过大的数，各运行一次第5课。

- 恢复默认值，写下合法检索与错误调用的不同执行路径。

观察什么：超出契约范围的参数收到明确拒绝，不会因为模型提出请求就直接执行。

机制解释：校验发生在执行之前，使工具权限与资源限制成为代码规则。

常见问题

工具名称不存在

原因：调用方使用了未注册名称。

处理：查看工具列表并使用精确名称，不通过模糊匹配自动选一个危险的相似动作。

输出为空但不知是否失败

原因：把成功的空结果与执行异常混淆。

处理：先查看状态与错误字段，再判断是否真的没有命中材料。

03 • 验收

第5课运行结果、一次参数对照，以及自己能解释的学习笔记。

成果文件：outputs/day05.json

☐ 能描述一个工具的输入、输出、错误与权限。

☐ 至少运行两种不合法top_k的对照。

☐ 能说明白名单没有自动解决内容可信和科学方法有效性。

自测与解析

1. 模型请求一个不在白名单中的工具，应怎样处理?

- A. 自动安装并运行它

- B. 拒绝并返回明确原因

- C. 把名字当终端命令

- D. 换成任意相近工具

答案：B。 允许执行的动作由程序确定，模型文本不能自动扩大权限。

2. 将专业分析流程包装成工具，能证明什么?

- A. 方法前提自动满足

- B. 研究结论已被独立验证

- C. 获得了可调用入口，仍需核对数据和方法前提

- D. 无需记录参数

答案：C。 包装解决接口问题，科学有效性仍依赖数据、设计、方法和验证。

小词典

- 工具契约：输入、输出、错误状态和权限的共同约定。

- 白名单：程序明确允许调用的有限工具集合。

- 最小权限：只给予当前任务确实需要的动作与数据访问范围。

04 · 我的记录

- 哪一个工具参数最容易被误解?

- 如果工具返回空结果，我如何判断它是正常情况还是故障?

忙碌日：20分钟

- 用3分钟读“工具是一个受约束的函数入口”，写下一个关键区别。

- 用12分钟运行 python run.py day 5，打开 outputs/day05.json 并核对第一项预期结果。

- 用5分钟完成第一道自测并写一句解释；完整参数实验和其余验收留待下次。

留下本课运行结果与一句自己的解释；精简完成单独记录，不等于完整课程已经验收。

有余力再做：20分钟选学 · 给一个工具补负例

- 写出一个应该使用该工具的任务。

- 再写两个不应该交给它的任务。

- 将这三个例子加入工具说明，帮助调用者理解边界。

参考资料与阅读范围

BioAgentLab：工具契约：对照输入、输出、失败与权限四种契约，不必通读全书。

https://github.com/zbyloveyj/BioAgentLab/blob/main/book/zh/06_tool_contracts.md

OpenAI 官方：Function calling：阅读工具定义、模型提出调用、程序执行及返回结果的流程。

https://platform.openai.com/docs/guides/function-calling

下一步

下一课把工具连接成能够观察结果并按预算停止的循环。