第08天 · 给材料建立来源与版本档案

从导入记录开始，让每次实验能够追溯材料变化。

标准路线：60分钟；忙碌日：20分钟；扩展练习另计。

今天的目标

- 识别导入记录的文字与元数据。

- 观察内容摘要随记录变化。

- 区分本次语料副本与永久修改原资料库。

开始之前

- 完成第7课，或能在practice目录运行日课命令。

- 只使用教学材料；修改配置前保留原值，实验结束后恢复或记下修改。

一小时安排

- 15分钟 · 理解概念：阅读四节讲解，记下今天最关键的一个区别；外部资料按指定小节选读。

- 30分钟 · 操作与修改：先完成四步带练，再改变一个参数，保留修改前后的结果。

- 10分钟 · 验收与自测：对照三项验收，完成两道自测并阅读解析。

- 5分钟 · 记录与收尾：写下结果、未解决的问题和下次打开项目后的第一步。

01 · 理解概念

先登记材料，再讨论检索效果

没有稳定来源，回答很难复查。导入一条材料时，至少应知道它的标题、内容、标识与来源范围；有条件时还要记录作者、日期、许可和读取时间。材料越杂，越需要明确哪些字段来自原文，哪些是自己的注释。

本课导入的是一个自写教学记录，并追加到本次运行的语料副本。它不会自动改写data/evidence.json，也没有实现通用PDF解析或全网抓取。先把一个可控例子做对，再考虑复杂格式。

摘要用于识别版本，不负责评价真假

程序为记录计算SHA-256摘要。相同规范化输入通常得到相同摘要，输入改变时摘要也会改变，因此可以用来检查本次实验是否仍使用同一版材料。摘要长度固定，不能从摘要还原全部原文。

摘要不告诉你材料是否真实、是否来自权威来源或是否符合研究伦理。它解决“是否发生变化”的识别问题；来源质量、内容准确和许可仍需另外检查。

内容与元数据都可能影响实验

只改文字会影响检索内容，只改标题或日期也可能改变材料解释与版本标记。当前实现对整条imported_record做稳定JSON序列化，再计算SHA-256；键按名称排序、使用紧凑分隔符与UTF-8编码。因此只改title或只改text都会改变摘要。你将分别修改并观察，而不是只凭字段名字猜测。

科研工程中还需要把材料版本与配置、代码版本一起记录。只保存一个最终回答，往往无法知道后来不同结果究竟来自模型变化、材料变化还是参数变化。

用本次副本练习，减少不可逆操作

本课运行时构建语料副本，输出导入记录与前后条数，便于检查新增是否发生。重跑相同命令不意味着原始资料文件被永久扩充；你应查看records_before和records_after，并核对data文件是否改变。

以后实现真正持久导入时，还要考虑重复ID、重复内容、版本覆盖、错误回滚和删除。不要在这一课混入未经整理的个人或临床资料；用自写的短说明就足以观察机制。

02 · 一步一步做

命令在解压后的 practice 文件夹执行。Windows可使用 .\.venv\Scripts\python.exe；macOS/Linux可使用 .venv/bin/python 替代 python。

1. 运行一次教学导入

为什么做：认识导入结果与语料副本。

使用默认record_title和record_text运行。

```
python run.py day 8
```

预期结果：得到imported_record、content_sha256和前后记录数。

2. 核对输入与新增记录

为什么做：证明输出确实来自当前配置。

打开结果，核对标题、文字与记录数差异。

```
python -m json.tool outputs/day08.json
```

预期结果：本次副本包含新增记录，原始资料文件并未被永久改写。

3. 只修改文字

为什么做：观察版本标记随材料变化。

把day08.record_text末尾加上“Review the original source before reuse.”，保存并重跑。

```
python run.py day 8
```

预期结果：导入文字更新；比较content_sha256是否改变。

4. 保留版本对照

为什么做：让后续检索实验知道自己读的是哪版资料。

将两次标题、文本改动、摘要和日期记录到笔记；恢复或明确保留修改后的配置。

预期结果：留下可解释的材料版本差异，而不是只记录“运行成功”。

改一改 · 标题和正文，分别会带来什么变化?

- 先运行默认第8课并保存摘要。

- 只改day08.record_title，运行并记录变化。

- 恢复标题，只改record_text再运行；结合源代码说明哪些字段参与当前摘要。

观察什么：只改变标题或只改变正文，都会改变content_sha256；当前摘要覆盖整条导入记录。

机制解释：版本追踪需要明确摘要覆盖的输入范围，不能把一个哈希当成来源可信度评分。

常见问题

重跑后原资料没有变多

原因：误把内存副本导入当成永久保存。

处理：查看records_before/records_after与输出记录；本课不修改data/evidence.json。

认为哈希相同就能证明内容可信

原因：混淆版本一致和事实准确。

处理：分别记录一致性检查与人工来源审查，两者不能互相替代。

03 · 验收

第8课运行结果、一次参数对照，以及自己能解释的学习笔记。

成果文件：outputs/day08.json

☐ 能指出导入记录的标题、文字与摘要。

☐ 完成标题/正文的单变量对照。

☐ 能说明导入只影响本次语料副本，未自动改写原资料库。

自测与解析

1. SHA-256摘要最适合帮助检查什么？

- A. 这段文字是否属于科学共识

- B. 当前输入是否与已记录版本一致

- C. 作者是否有足够资历

- D. 研究结论是否因果成立

答案：B。 摘要可识别输入版本，不能判断内容的科学质量。

2. 本课导入新记录后，原始data/evidence.json会怎样？

- A. 自动永久追加

- B. 自动删除旧版本

- C. 保持原文件，本次运行使用新增后的副本

- D. 自动上传到网络

答案：C。 课程把导入范围限定在本次语料副本，避免把教学步骤与持久数据管理混为一谈。

小词典

- 元数据：描述材料来源、标题、时间与用途等信息的字段。

- 摘要/Hash：由输入计算的固定长度版本标记。

- Provenance：描述数据从何而来、经过何种处理的来源记录。

04 · 我的记录

- 如果两次回答不同，我是否能检查它们使用的材料版本?

- 哪些来源字段在我的科研工作中不可省略?

忙碌日：20分钟

- 用3分钟读“先登记材料，再讨论检索效果”，写下一个关键区别。

- 用12分钟运行 python run.py day 8，打开 outputs/day08.json 并核对第一项预期结果。

- 用5分钟完成第一道自测并写一句解释；完整参数实验和其余验收留待下次。

留下本课运行结果与一句自己的解释；精简完成单独记录，不等于完整课程已经验收。

有余力再做：20分钟选学 · 设计一张材料登记表

- 列出ID、来源URL、版本、读取日期与许可。

- 增加“原文”和“人工注释”的区别。

- 写出重复导入时应新增版本还是拒绝的规则。

参考资料与阅读范围

Python 官方：hashlib：查看sha256的输入与hexdigest输出；理解摘要用于识别内容版本。

https://docs.python.org/3/library/hashlib.html

BioAgentLab：Agentic RAG 与证据：关注证据台账、来源与回答之间的对应关系。

https://github.com/zbyloveyj/BioAgentLab/blob/main/book/zh/10_agentic_rag_and_evidence.md

下一步

下一课把材料切成块，建立可以解释的词项检索基线。