第09天 · 做一个可以解释的检索基线

比较分块、重叠与词项排序，不急着追逐复杂框架。

标准路线：60分钟；忙碌日：20分钟；扩展练习另计。

今天的目标

- 理解分块如何影响证据单元。

- 调整chunk_size和top_k并观察结果。

- 区分词项检索与向量检索。

开始之前

- 完成第8课，或能在practice目录运行日课命令。

- 只使用教学材料；修改配置前保留原值，实验结束后恢复或记下修改。

一小时安排

- 15分钟 · 理解概念：阅读四节讲解，记下今天最关键的一个区别；外部资料按指定小节选读。

- 30分钟 · 操作与修改：先完成四步带练，再改变一个参数，保留修改前后的结果。

- 10分钟 · 验收与自测：对照三项验收，完成两道自测并阅读解析。

- 5分钟 · 记录与收尾：写下结果、未解决的问题和下次打开项目后的第一步。

01 · 理解概念

分块决定检索返回什么大小的材料

整篇材料可能太长，一句话又可能缺少上下文。分块将材料切成可以检索和引用的片段。块太小容易拆开限定条件；块太大可能混入很多无关内容。选择块大小应根据材料结构和问题类型做对照。

本课以字符长度与重叠数量演示分块，便于看见参数如何影响片段。它不是按模型token精确切分，也不自动理解句子、表格或方法段落的语义边界。

重叠有作用，也有代价

相邻片段保留一些重叠文字，可以减少边界附近信息被切断的机会。但重叠太大，会带来重复结果、更多存储与处理开销；也可能让评价表里看起来找到很多证据，实际上来自同一段文字。

因此除了看命中数量，还要读结果是否互相重复、是否包含完整限定条件，以及能否回到原始记录。片段ID与原记录ID都值得保留，便于合并和追踪。

先理解一个词项基线

本课按词项匹配给片段排序，查询词与材料中的词有重合时容易命中。优点是过程直观、容易调试，缺点是同义词、跨语言和语义改写可能漏检。它不是已经接入embedding模型的向量数据库。

向量检索可以作为后续扩展，但也需要独立评价。不要因为换成更复杂的表示，就假定召回和答案正确性一定提高。一个解释清楚的简单基线，是比较改进是否有效的起点。

top_k控制返回数量，不自动控制质量

top_k决定最多保留多少个高分结果。较小值可能漏掉必要资料；较大值可能引入无关或冲突材料。排序靠前只能说明当前评分较高，不意味着该片段具有更高科学可信度。

本课每次改一个条件，记录块数、命中片段、重复情况和是否包含完整依据。先看内容，再看分数；后面的评价课会用预先标注的问题检查检索是否找到了该找的证据。

02 · 一步一步做

命令在解压后的 practice 文件夹执行。Windows可使用 .\.venv\Scripts\python.exe；macOS/Linux可使用 .venv/bin/python 替代 python。

1. 运行分块与检索

为什么做：取得可以复查的基线。

保留默认query、chunk_size、overlap和top_k。

```
python run.py day 9
```

预期结果：得到chunks和retrieved，能够看见原记录与片段内容。

2. 手工检查一个片段

为什么做：确认分块没有神奇理解语义。

打开结果，选一个片段找出其原记录，查看开头与结尾是否切断关键限定条件。

```
python -m json.tool outputs/day09.json
```

预期结果：能说明一个片段为什么有用或为什么需要上下文。

3. 改变块大小

为什么做：观察片段数量与信息完整性的变化。

保持query、overlap和top_k不变，将day09.chunk_size从80改为120并重跑。

```
python run.py day 9
```

预期结果：块数和片段范围随长度变化；不要求分数一定提高。

4. 恢复并比较返回数量

为什么做：把检索参数与可见结果对应。

恢复块大小，再分别用top_k=1和3运行，记录多出的片段是否有帮助。

预期结果：留下参数、结果和人工判断三列对照。

改一改 · 同义改写能被词项基线找到吗?

- 先用默认day09.query运行并保存retrieved。

- 将query改成含同义表达或中文的问题，保留其他条件再运行。

- 比较词项命中，说明遗漏是否可能来自语言形式；恢复能复现的查询。

观察什么：词面变化可能改变排序甚至导致漏检；这不表示原材料不存在。

机制解释：检索表示有自己的能力边界，理解漏检原因比只看一个分数更能指导改进。

常见问题

重叠参数导致分块异常

原因：overlap接近或超过chunk_size。

处理：保持0≤overlap<chunk_size；恢复默认80/16后再逐项修改。

问题明显相关却找不到

原因：查询与材料没有足够词项重合。

处理：先用材料中的关键词验证基线，再记录同义词/跨语言的局限，而不是假称语料没有证据。

03 · 验收

第9课运行结果、一次参数对照，以及自己能解释的学习笔记。

成果文件：outputs/day09.json

☐ 能指出字符分块与token分块的差别。

☐ 完成块大小或top_k的真实参数对照。

☐ 能给出一个词项检索可能漏检的同义改写例子。

自测与解析

1. top_k从1增加到3，最直接改变什么?

- A. 材料的真实性

- B. 允许返回的最大结果数量

- C. 模型参数数量

- D. 研究设计质量

答案：B。 top_k改变选择数量，是否更好仍要检查新增材料的相关性和支持作用。

2. 本课的chunk_size按什么计算?

- A. 模型token

- B. 研究样本数

- C. 字符长度

- D. 嵌入向量维度

答案：C。 字符切分便于观察机制，但与模型token计数或语义段落并不等价。

小词典

- Chunk：从原始材料切出的可检索片段。

- Overlap：相邻片段共享的文字范围。

- 词项检索：根据查询和材料中的词项匹配进行选择与排序。

04 · 我的记录

- 哪一个片段虽然命中关键词，却没有真正回答问题?

- 如果改用向量检索，我会用哪些相同问题做比较?

忙碌日：20分钟

- 用3分钟读“分块决定检索返回什么大小的材料”，写下一个关键区别。

- 用12分钟运行 python run.py day 9，打开 outputs/day09.json 并核对第一项预期结果。

- 用5分钟完成第一道自测并写一句解释；完整参数实验和其余验收留待下次。

留下本课运行结果与一句自己的解释；精简完成单独记录，不等于完整课程已经验收。

有余力再做：20分钟选学 · 为检索建立三条人工判断

- 选择一条应命中的问题、一条同义改写、一条无答案问题。

- 为每条写期望来源与理由。

- 用相同问题比较两组参数，避免只展示最好看的案例。

参考资料与阅读范围

BioAgentLab：Agentic RAG 与证据：关注证据台账、来源与回答之间的对应关系。

https://github.com/zbyloveyj/BioAgentLab/blob/main/book/zh/10_agentic_rag_and_evidence.md

RAG 原始论文：只读摘要与方法概览；本课词项检索教学基线不复现论文模型。

https://arxiv.org/abs/2005.11401

下一步

下一课把检索结果组织成带引用的回答，并检查引用能否回到材料。