第10天 · 让回答带着证据一起出现

把检索、引用与无证据时停止连接起来。

标准路线：60分钟；忙碌日：20分钟；扩展练习另计。

今天的目标

- 解释RAG中检索与生成分别负责什么。

- 核对回答中的证据ID与摘录。

- 用无支持问题检查系统是否克制。

开始之前

- 完成第9课，或能在practice目录运行日课命令。

- 只使用教学材料；修改配置前保留原值，实验结束后恢复或记下修改。

一小时安排

- 15分钟 · 理解概念：阅读四节讲解，记下今天最关键的一个区别；外部资料按指定小节选读。

- 30分钟 · 操作与修改：先完成四步带练，再改变一个参数，保留修改前后的结果。

- 10分钟 · 验收与自测：对照三项验收，完成两道自测并阅读解析。

- 5分钟 · 记录与收尾：写下结果、未解决的问题和下次打开项目后的第一步。

01 · 理解概念

RAG给回答补充可定位的材料

RAG把检索得到的材料交给回答环节，使结果可以依据当前资料，而不只依赖模型已有知识。本课先检索教学记录，再组织回答与引用；离线模式由规则完成，真实模型路径可在已配置时另做比较。

RAG不是把任意文件塞进提示后就保证正确。导入可能漏内容，检索可能选错，回答可能夸大，引用也可能张冠李戴。必须把这些环节拆开检查，才能知道应该改哪一部分。

引用需要一个能够回到原文的锚点

每条引用应尽量带原记录ID、来源和对应文字。拿到结果后，先检查引用ID是否存在，再检查quote是否来自该记录，最后检查引用是否支持答案中的具体主张。三步缺一不可。

程序可以较容易检查ID和文字匹配，但“材料是否真正支持结论”往往仍需人工判断。摘录存在，不等于科学推断成立；例如材料讨论相关性，回答却下因果结论，仍然需要纠正。

没有支持材料时，停止也是结果

当问题超出当前资料范围，系统应明确说明证据不足。拒答不代表系统一无是处，它让使用者知道需要补材料、换工具或把问题转交给人。用猜测填补空白会让后续研究更难复查。

拒答策略也需要评价：过于保守可能漏答本来有依据的问题，过于宽松可能给出没有支持的答案。因此要同时准备有答案和无答案的例子，并分别记录。

区分来源支持与材料本身的质量

即使回答忠于某份材料，那份材料仍可能过时、错误或只适用于特定条件。课程中的教学记录用于演示接口，不能代替系统检索完整文献、评价研究设计或形成真实研究结论。

在自己的工作中，可以把结果分成“材料明确支持”“合理但待核验的推断”“当前无证据”三类。先保持边界，再逐步增加高质量来源与更可靠的检查。

02 · 一步一步做

命令在解压后的 practice 文件夹执行。Windows可使用 .\.venv\Scripts\python.exe；macOS/Linux可使用 .venv/bin/python 替代 python。

1. 运行带引用问答

为什么做：先得到可检查的完整结果。

用默认day10.question运行。

```
python run.py day 10
```

预期结果：得到answer与引用，保留模式和终止状态。

2. 从引用回到材料

为什么做：检验可追溯性。

打开输出，并根据evidence_id在data/evidence.json找到对应记录。

```
python -m json.tool outputs/day10.json
```

预期结果：能核对一条引用的原文，并用自己的话说明它支持哪一句。

3. 改变问题

为什么做：检验材料范围，而不是只展示成功例子。

将day10.question改为当前教学库没有依据的具体问题，保存后重跑。

```
python run.py day 10
```

预期结果：观察是否拒答或给出证据不足；如错误回答，应如实记录为失败。

4. 恢复并写边界

为什么做：给结果增加可使用的解释。

恢复默认问题，写出检索命中、引用匹配与科学支持这三层检查的不同。

预期结果：保留一份可回答和一份无支持问题的结果。

改一改 · 固定检索参数，只改变问题

- 保留day10.top_k=3，使用默认question运行第10课并记录status和citations。

- 仅将question改为zephyrquartz gondola 92851，再运行python run.py day 10，检查是否出现abstained与空引用。

- 恢复默认问题。这个人为无匹配串只验证无命中分支；另选自然语言问题检查，若词面误命中造成错误回答，就如实登记失败。

观察什么：默认问题有教学资料支持；人为无匹配串进入明确拒答路径。自然语言难题仍需逐项人工检查，不能因这个简单负例通过就认为拒答可靠。

机制解释：一次只改变问题可以检验材料范围与无命中行为；引用是否支持更强主张仍需另外核对。

常见问题

引用存在但与结论无关

原因：把检索相关性当成语义支持。

处理：按句子核对材料实际说了什么，删除或改写没有依据的结论。

无答案问题仍出现肯定答案

原因：拒答策略或检索阈值存在不足。

处理：保存失败输入和输出，纳入后续评价；不能只删除不理想的案例。

03 • 验收

第10课运行结果、一次参数对照，以及自己能解释的学习笔记。

成果文件：outputs/day10.json

☐ 至少核对一条引用ID、摘录与对应主张。

☐ 运行一次材料外的问题并如实记录状态。

☐ 能说明RAG没有自动消除事实错误和科学推断风险。

自测与解析

1. 检查引用时，哪一步不能省?

- A. 只看URL能否打开

- B. 只看引用数量

- C. 核对来源内容是否支持具体主张

- D. 只看回答长度

答案：C。 可访问来源与引用数量都不能替代主张层面的证据核验。

2. 当前资料没有问题所需证据时，合理结果是什么?

- A. 编一个最可能的答案

- B. 无限重复同样检索

- C. 说明不足并指出需要补充的材料

- D. 隐藏引用字段

答案：C。 清楚暴露证据缺口，比生成无法复查的猜测更有助于后续工作。

小词典

- RAG：检索相关材料，并让回答环节基于这些材料组织结果的方法。

- Grounding：把输出中的主张与可定位的材料连接起来。

- 拒答/Abstention：在支持条件不足时明确不提供肯定结论。

04 · 我的记录

- 哪句话来自原文，哪句话来自我的推断?

- 如果资料是错的，即使忠实引用，我还需要哪一道检查?

忙碌日：20分钟

- 用3分钟读“RAG给回答补充可定位的材料”，写下一个关键区别。

- 用12分钟运行 python run.py day 10，打开 outputs/day10.json 并核对第一项预期结果。

- 用5分钟完成第一道自测并写一句解释；完整参数实验和其余验收留待下次。

留下本课运行结果与一句自己的解释；精简完成单独记录，不等于完整课程已经验收。

有余力再做：20分钟选学 · 给同一回答做一次红笔复核

- 把每句主张旁边写上证据ID。

- 找出没有明确支持的句子。

- 将其删除、弱化或标为待验证推断，并记录原因。

参考资料与阅读范围

BioAgentLab：Agentic RAG 与证据：关注证据台账、来源与回答之间的对应关系。

https://github.com/zbyloveyj/BioAgentLab/blob/main/book/zh/10_agentic_rag_and_evidence.md

RAG 原始论文：只读摘要与方法概览；本课词项检索教学基线不复现论文模型。

https://arxiv.org/abs/2005.11401

下一步

下一课用标注问题评价检索与拒答，不再只看单个成功演示。