第11天 · 用小评价集检查检索与拒答

把“看起来不错”转成有分母、能定位失败的观察。

标准路线：60分钟；忙碌日：20分钟；扩展练习另计。

今天的目标

- 计算并解释证据召回与两类通过率。

- 用同一组问题比较top_k=1和3。

- 区分公开开发集表现与真实场景可靠性。

开始之前

- 完成第10课，或能在practice目录运行日课命令。

- 只使用教学材料；修改配置前保留原值，实验结束后恢复或记下修改。

一小时安排

- 15分钟 · 理解概念：阅读四节讲解，记下今天最关键的一个区别；外部资料按指定小节选读。

- 30分钟 · 操作与修改：先完成四步带练，再改变一个参数，保留修改前后的结果。

- 10分钟 · 验收与自测：对照三项验收，完成两道自测并阅读解析。

- 5分钟 · 记录与收尾：写下结果、未解决的问题和下次打开项目后的第一步。

01 · 理解概念

评价首先要说明题目与标准

评价集是一组问题及其预先写明的期望。今天使用data/eval_dev.json公开教学开发集，其中可回答题具有应出现的证据ID，不可回答题没有支持证据。先读一条题目和标签，再看系统表现，避免事后根据输出修改正确答案。

这些案例数量很小、全部公开，适合发现接口与流程问题。它们不是隐藏测试，更不是对真实科研能力的独立验证。开发集上得分提高，说明在这套明确规则下变好；是否能推广到新问题，需要另做评价。

检索召回回答的是“找回来多少”

一条可回答题的证据召回等于“检索到的期望证据数量÷全部期望证据数量”。例如需要E03和E07，只找到E07，这条题的召回是1/2。当前程序对可回答题逐题计算，再求平均；无支持证据题的召回记为null，不把它塞进相同分母。

召回不惩罚所有无关材料。找回正确证据的同时夹入很多噪声，召回仍可能很高。因此要打开items检查具体结果，并考虑回答是否引用全部必要材料、是否引入不支持的主张。不要用一个数字替代全部质量判断。

可回答与不可回答分别检查

当前answerable_accuracy的通过条件是状态为answered，且引用集合包含该题全部期望证据ID。abstention_accuracy则统计本来没有支持证据的题，系统是否返回abstained。它们是教学程序的规则指标，不会自动判断自然语言中的每个科学结论。

这个区别能发现一种常见失败：系统给出了答案，引用也真实，却遗漏了题目必须同时考虑的另一条证据。另一种失败是任何问题都回答；如果没有单独设置不可回答题，漂亮的总体结果可能掩盖这种问题。

让检索与回答使用同一个实验条件

今天的top_k同时传给检索和回答路径，避免一边评价取1条、另一边回答偷偷取3条。先用1，再用3，其他条件保持不变。比较时记录配置、每个指标的分母，以及哪一题发生变化。

当前教学集D6要求同时覆盖E03和E07，top_k=1无法同时取回两条；top_k=3能够展示完整覆盖的区别。这个案例说明了指标如何定位缺口，不代表以后top_k越大越好：更多材料也会增加噪声和上下文成本。

02 · 一步一做

命令在解压后的 practice 文件夹执行。Windows可使用 .\.venv\Scripts\python.exe；macOS/Linux可使用 .venv/bin/python 替代 python。

1. 运行公开开发集

为什么做：建立与后续修改可比较的基线。

保持day11.split为dev、top_k为3，运行本课。

```
python run.py day 11
```

预期结果：得到evaluation中的retrieval_recall、answerable_accuracy、abstention_accuracy和items。

2. 直接比较两个检索数量

为什么做：确保参数真实传入评价程序。

依次运行下面两条命令，把两次终端结果复制到学习笔记；同名evaluation_dev.json会更新。

```
python run.py evaluate --split dev --top-k 1
python run.py evaluate --split dev --top-k 3
```

预期结果：top_k=1时D6缺少部分期望证据；top_k=3时该教学案例覆盖完整。

3. 回到失败题核对分母

为什么做：从指标追到具体材料。

打开开发集与结果，找到D6的expected和retrieved，再人工算一次该题召回。

```
python -m json.tool data/eval_dev.json
python -m json.tool outputs/evaluation_dev.json
```

预期结果：能够解释这条题的1/2与整体平均值为什么不同。

4. 写一段评价结论

为什么做：把观察与推广范围分开。

用三句话记录配置、发生变化的案例、仍未检验的能力；不要把公开小题集得分写成科学结论正确率。

预期结果：结论包含分母与适用范围，指出仍需人工核对语义支持。

改一改 · 让D6从部分证据变成完整证据

- 在experiments.json中只把day11.top_k改为1，运行python run.py day 11。

- 记录D6的expected、retrieved、recall和passed，再将top_k改回3运行。

- 对照其余题是否变化；解释为什么当前测试的改善不意味着所有问题都应增加检索数量。

观察什么：当前公开教学集中D6从部分覆盖变为完整覆盖；指标计算使用同一个top_k驱动检索与回答。

机制解释：逐题记录让数字变化具有可解释的原因；结果仅反映本套公开开发题的规则检查。

常见问题

只看到最终一次评价结果

原因：两次命令写入同名输出文件。

处理：运行下一次前复制终端结果到笔记，或给自己的记录注明配置；不要把两次混成一份。

达到满分就认为可以交付真实研究

原因：当前题目很少且已公开，指标按证据ID和状态计算。

处理：追加人工检查与新问题，并把公开开发集范围写入报告；不要修改标签迎合输出。

03 • 验收

第11课运行结果、一次参数对照，以及自己能解释的学习笔记。

成果文件：outputs/day11.json

☐ 手工计算过一条题的证据召回。

☐ 保留top_k=1与3两次对照并指出D6的具体变化。

☐ 说明拒答率、可回答题通过率与科学语义正确性不是同一件事。

自测与解析

1. 一题需要E03和E07，检索只找到E07，该题召回是多少?

- A. 0

- B. 1/2

- C. 1

- D. 无法计算

答案：B。 已找到1条期望证据，共需2条，因此召回是1/2；无关材料多少不改变这个分母。

2. 公开开发集上的高分最直接说明什么?

- A. 所有科研问题都能正确回答

- B. 模型拥有真实科研能力

- C. 当前实现通过了这套已知题目的规定检查

- D. 无需再检查拒答

答案：C。 它证明的是明确题集与指标下的表现，不能替代未知问题测试或科学语义验证。

小词典

- 召回：检索到的期望证据占全部期望证据的比例。

- 开发集：用于观察和改进系统的已知案例集合。

- 拒答评价：检查没有支持材料时是否明确停止作答。

04 · 我的记录

- 哪一条失败最值得先修：没检索到、引用不完整，还是该拒答却回答？

- 自己的真实问题应如何写出可检查的期望，而不只写“答案很好”？

忙碌日：20分钟

- 用3分钟读“评价首先要说明题目与标准”，写下一个关键区别。

- 用12分钟运行 python run.py day 11，打开 outputs/day11.json 并核对第一项预期结果。

- 用5分钟完成第一道自测并写一句解释；完整参数实验和其余验收留待下次。

留下本课运行结果与一句自己的解释；精简完成单独记录，不等于完整课程已经验收。

有余力再做：20分钟选学 · 手工扩展一条评价案例

- 选择一个必须同时考虑两条教学证据的问题。

- 写出期望证据ID和为什么两条都需要，不先改程序。

- 记录当前输出，再判断问题、标签和评价规则是否一致。

参考资料与阅读范围

BioAgentLab：评价与校准：关注评价单位、失败分类、拒答和人工复核。

https://github.com/zbyloveyj/BioAgentLab/blob/main/book/zh/18_evaluation_and_calibration.md

BioAgentLab：Agentic RAG 与证据：关注证据台账、来源与回答之间的对应关系。

https://github.com/zbyloveyj/BioAgentLab/blob/main/book/zh/10_agentic_rag_and_evidence.md

下一步

下一课把中间状态保存下来，让任务可以从已完成阶段继续。