第20天 · 让研究者、质疑者和复核者各司其职

用不同职责发现问题，避免把角色数量当作可靠性。

标准路线：60分钟；忙碌日：20分钟；扩展练习另计。

今天的目标

- 解释研究者、质疑者、复核者的输入输出。

- 观察引用要求如何影响规则复核。

- 区分角色分工、独立证据与真实多模型调用。

开始之前

- 已经完成第 19 课，或能解释其产物。

- 打开实践包 practice 目录；后文 python 可替换为虚拟环境内解释器的完整路径。

一小时安排

- 15分钟 · 理解概念：阅读本课四节讲解，弄清一个关键机制与适用边界。

- 30分钟 · 亲手操作：先跑基线，再做一次单变量实验，保留前后结果。

- 10分钟 · 检查结果：逐项验收，完成两道自测并阅读解析。

- 5分钟 · 留下记录：写出本课发现、未解决问题和下次第一步。

01 · 理解概念

先按职责拆分，而不是按人数拆分

研究者整理候选回答与来源，质疑者寻找缺少依据的句子，复核者决定结果能否通过。每个角色应有可检查的输入与输出；三个角色重复同一句话并没有增加独立证据。

本课使用规则实现角色分工，结果中会明确标识。它展示责任划分与信息交接，不是同时运行三个真实大语言模型，也不代表模型之间已经完成独立评审。

质疑要指向具体证据缺口

有效的质疑是“这句话没有对应来源”或“引用只支持关联，不能支持因果”。只说“请更严谨”通常难以转化为下一步动作。把问题写成可复核条目，才能让研究者有针对性地补充。

机器规则只能发现预先定义的一部分错误，例如缺少引用；它不一定能判断引文是否真正支持结论。这里要保留人工复核入口，不把规则未报错解释成科学论证没有漏洞。

复核者需要公开的通过标准

require_citations 表示是否要求引用。这个参数应影响复核行为，而不是只改变显示文案。你可以比较开启和关闭时的反馈，并说明为什么科研任务通常应保留来源要求。

通过标准越宽松，通过率可能越高，但结果不一定更可靠。评估时应同时查看错误漏检与错误拒绝，不能把通过率当成唯一优化目标。

多角色会带来额外成本

真实模型版本中的多角色通常需要更多调用、更多等待和更多上下文。只有当职责分工能减少具体错误时，这些额外开销才有理由。简单任务可以使用单个明确流程。

同一模型反复扮演不同角色，仍可能共享相同偏差。后面评价课程会要求用外部可检查的案例与标准衡量表现，而不是让系统自己给自己打满分。

02 · 一步一步做

命令在解压后的 practice 文件夹执行。Windows可使用 .\.venv\Scripts\python.exe；macOS/Linux可使用 .venv/bin/python 替代 python。

1. 找到本课的输入与配置

为什么做：先知道程序读什么，后面才能解释输出为何改变。

在 VS Code 中打开 experiments.json，定位 day20。用下面的命令确认当前目录正确，并把各参数的作用写在笔记中。

```
python -c "import json; print(json.load(open('experiments.json', encoding='utf-8'))['day20'])"
```

预期结果：终端显示本课配置；键名与文件中的内容一致。

2. 运行本课基线

为什么做：保持默认设置的一次运行，是后续比较的参照。

执行命令，打开新生成的 outputs/day20.json。先检查 day、mode 和 result，不急着修改代码。

```
python run.py day 20
```

预期结果：结果写入 outputs/day20.json；主线 mode 明确为 offline，代表规则教学流程。

3. 沿输出检查机制

为什么做：不能只看程序有没有报错，要检查它实际做了什么。

格式化阅读输出，重点检查researcher、critic、reviewer 与 mode。把一个输入参数和一个输出字段用箭头对应起来。

```
python -m json.tool outputs/day20.json
```

预期结果：能够定位researcher、critic、reviewer 与 mode，并用自己的话解释该结果。

4. 改变一个条件并比较

为什么做：主动制造可解释的变化，才能验证自己理解的机制。

完成下面“改一改”实验。对比基线与新结果，记录哪些字段改变、哪些保持稳定；不要同时改模型、材料和参数。

预期结果：留下一组前后结果和一句解释；失败状态也可以是正确的实验产物。

改一改 · 关闭引用要求，审视通过标准是否变松

- 先执行 python run.py day 20，将 outputs/day20.json 复制为自己的基线备份。

- 在 VS Code 打开 experiments.json，只修改 day20.require_citations 为 false，保持其他键不变并保存。

- 执行 python -m json.tool experiments.json 检查语法，再执行 python run.py day 20。

- 对比两份结果，重点观察researcher、critic、reviewer 与 mode；解释改变原因后恢复原设置或明确记录保留值。

观察什么：对比 reviewer 的标准或检查项；部分基线本身已有引用，最终通过状态可能不变，这也是应记录的结果。

机制解释：参数改变不保证每个样例都改变最终标签；需要同时查看规则配置与中间信息，避免只盯通过或失败。

常见问题

修改配置后结果没有变化

原因：改了其他天的字段，或编辑后尚未保存。

处理：核对 experiments.json 中的 day20，保存后重新运行；检查实际执行目录。

把受控失败误当成程序坏了

原因：本课实验主动制造了边界条件。

处理：先对照 expected 和状态字段，区分设计内拒绝与未处理异常；保留错误信息再修复。

03 • 验收

用不同职责发现问题，避免把角色数量当作可靠性。 保留基线、修改结果与自己的解释。

成果文件：outputs/day20.json

☐ 能指出三种角色各自负责的检查。

☐ 比较修改前后要求与反馈，允许最终标签相同。

☐ 明确本课为规则角色示范，并保留科学人工复核。

自测与解析

1. 三个角色都同意一个结论，是否相当于三份独立证据?

- A. 是

- B. 只有用了不同名字才是

- C. 不是，可能共享来源和偏差

- D. 同意次数越多越确定

答案：C。 角色一致不能替代独立资料、方法或研究证据。

2. 参数变化后最终通过状态不变，首先应做什么?

- A. 认定参数没生效

- B. 查看检查条件、中间结果与样例是否触发差异

- C. 随意改其他参数

- D. 删除原始结果

答案：B。 某个样例可能同时满足两套标准，应检查执行路径再判断。

小词典

- Critic：按明确标准寻找缺口与反例的角色。

- Reviewer：依据验收标准决定是否进入下一步的角色。

- Correlated error：多个角色因共享模型或材料而产生的相关错误。

04 · 我的记录

- 哪类错误需要另一个角色，哪类错误用一个断言更直接?

- 我的复核标准会不会因为追求高通过率而被放松?

忙碌日：20分钟

- 用5分钟阅读第一个概念，写出本课要解决的问题。

- 用10分钟运行 python run.py day 20，打开 outputs/day20.json，检查一个关键字段。

- 用5分钟完成第一道自测并留一句解释，完整实验与验收留到下次。

保存一份运行结果和自己的解释；精简练习单独记录，不等于整课验收全部完成。

有余力再做：20分钟选学 · 把本课机制迁移到一个自己的任务

- 从自己的文献整理或数据分析流程中选一个相似环节。

- 写清输入、允许动作、失败出口与验收方法。

- 提出一个会让当前实现失败的反例，并标明它是待实现扩展。

参考资料与阅读范围

Anthropic：Building effective agents：阅读并行、评估者—优化者及何时使用复杂工作流。

https://www.anthropic.com/research/building-effective-agents

BioAgentLab：科研 Agent 教材：围绕评价与文献Agent章节，对照角色输出和证据台账。

https://github.com/zbyloveyj/BioAgentLab

下一步

下一课把已有的研究流程整合成带质量门的阶段作品。