第29天 · 为未知、冲突与攻击建立失败案例册

让系统显露盲区，把应当拒绝和需要人工判断的情况留作交付证据。

标准路线：60分钟；忙碌日：20分钟；扩展练习另计。

今天的目标

- 识别材料外问题被无关证据误匹配的真实失败。

- 复现有限冲突规则的触发与未触发。

- 记录一个当前规则不能识别的反例。

开始之前

- 已经完成第 28 课，或能解释其产物。

- 打开实践包 practice 目录；后文 python 可替换为虚拟环境内解释器的完整路径。

一小时安排

- 15分钟 · 理解概念：阅读本课四节讲解，弄清一个关键机制与适用边界。

- 30分钟 · 亲手操作：先跑基线，再做一次单变量实验，保留前后结果。

- 10分钟 · 检查结果：逐项验收，完成两道自测并阅读解析。

- 5分钟 · 留下记录：写出本课发现、未解决问题和下次第一步。

01 · 理解概念

未知问题应该有明确出口

课程材料没有涵盖某个问题时，系统应说明证据不足。默认问题询问未知疾病的治疗，这不在教学语料能够支持的范围内，因此不应产生确定的治疗建议。

默认运行会暴露一个真实失败：unknown一词命中E08中“未知token与成本”的笔记，status可能是answered，却没有提供关于疾病治疗的相关证据。应把它记为未知识别失败，不能将非空回答当成回答正确。再用完全无匹配的问题对照，才能看见当前拒答仅覆盖部分情况。

证据冲突需要先识别再解释

两份材料可能给出不同结论，原因可能是研究对象、方法、时间或定义不同。不能只保留排在第一位的来源，也不能简单投票决定哪个结论正确。

本课conflict_review使用有限关键字与规则触发提醒，帮助你看见冲突检查的位置。它不是语义矛盾检测器，不能可靠识别隐含否定、数值差异、跨句推断或研究设计差异。

没有告警不等于没有冲突

include_conflict控制是否加入课程预设的冲突案例。关闭后告警可能消失，但你只能得出预设触发条件没有出现，不能推断所有资料在科学意义上已经一致。

写一个当前规则会漏掉的反例，例如“改善10%”与“未达到预设阈值”可能需要上下文才知道是否矛盾。把反例留在案例册里，明确它尚未被自动化覆盖。

失败案例比一句总评更有用

将未知问题误匹配、冲突提醒和攻击检查分别记录输入、预期、实际结果与是否需要人工接管。失败类型越具体，后续改进越容易对应到检索、工具、提示或审核机制。

本课与第23课同样使用离线规则，不声称完成真实模型红队测试。演示时要同时说明挡住了什么、没测什么、当前规则会漏什么，让使用者理解接管条件。

02 · 一步一做

命令在解压后的 practice 文件夹执行。Windows可使用 .\.venv\Scripts\python.exe；macOS/Linux可使用 .venv/bin/python 替代 python。

1. 找到本课的输入与配置

为什么做：先知道程序读什么，后面才能解释输出为何改变。

在 VS Code 中打开 experiments.json，定位 day29。用下面的命令确认当前目录正确，并把各参数的作用写在笔记中。

```
python -c "import json; print(json.load(open('experiments.json', encoding='utf-8'))['day29'])"
```

预期结果：终端显示本课配置；键名与文件中的内容一致。

2. 运行本课基线

为什么做：保持默认设置的一次运行，是后续比较的参照。

执行命令，打开新生成的 outputs/day29.json。先检查 day、mode 和 result，不急着修改代码。

```
python run.py day 29
```

预期结果：结果写入 outputs/day29.json；主线 mode 明确为 offline，代表规则教学流程。

3. 识别误匹配，再对照零命中问题

为什么做：不能只看程序有没有报错，要检查它实际做了什么。

检查默认unknown_answer：unknown一词可能命中E08，但该笔记没有疾病治疗证据，应记为失败。随后运行下方无匹配问题，比较状态与引用；这只展示零命中时的拒答，不能修复默认样例的误匹配。

```
python -m json.tool outputs/day29.json
python run.py ask "zxqv nebula recipe"
```

预期结果：默认样例出现无关E08摘录；对照问题为abstained。把两者记录成当前检索与拒答规则的边界。

4. 改变一个条件并比较

为什么做：主动制造可解释的变化，才能验证自己理解的机制。

完成下面“改一改”实验。对比基线与新结果，记录哪些字段改变、哪些保持稳定；不要同时改模型、材料和参数。

预期结果：留下一组前后结果和一句解释；失败状态也可以是正确的实验产物。

改一改 · 移除预设冲突样例，比较告警变化

- 先执行 python run.py day 29，将 outputs/day29.json 复制为自己的基线备份。

- 在 VS Code 打开 experiments.json，只修改 day29.include_conflict 为 false，保持其他键不变并保存。

- 执行 python -m json.tool experiments.json 检查语法，再执行 python run.py day 29。

- 对比两份结果，重点观察unknown_answer、conflict_review 与 attack_check；解释改变原因后恢复原设置或明确记录保留值。

观察什么：预设冲突触发条件不再出现时，conflict_review的结果相应变化；unknown_answer与独立攻击检查的职责仍分开。不要将无告警解释为语义上已无冲突。

机制解释：单变量实验只能说明当前规则对预设样例的反应，无法外推出对所有矛盾表达的识别能力。

常见问题

修改配置后结果没有变化

原因：改了其他天的字段，或编辑后尚未保存。

处理：核对 experiments.json 中的 day29，保存后重新运行；检查实际执行目录。

把受控失败误当成程序坏了

原因：本课实验主动制造了边界条件。

处理：先对照 expected 和状态字段，区分设计内拒绝与未处理异常；保留错误信息再修复。

03 • 验收

让系统显露盲区，把应当拒绝和需要人工判断的情况留作交付证据。 保留基线、修改结果与自己的解释。

成果文件：outputs/day29.json

☐ 记录默认问题误匹配E08的失败，不把answered标签当作治疗证据。

☐ 记录冲突检查前后结果及触发范围。

☐ 案例册包含一个未覆盖反例和清楚的人工接管条件。

自测与解析

1. 有限规则没有发现冲突，可以得出什么结论?

- A. 所有证据一致

- B. 本次输入没有触发当前规则

- C. 研究设计完全相同

- D. 无需阅读原文

答案：B。 规则覆盖面有限，无告警只能按实际检测条件解释。

2. 面对材料外治疗问题，最合理的输出是什么?

- A. 猜测一种疗法

- B. 说明证据不足并停止确定推断

- C. 引用任意无关材料

- D. 为了完整回答编造研究

答案：B。 证据边界应优先于回答完整度，尤其不能从教学语料推导不存在的医疗证据。

小词典

- Failure case：输入、预期和实际行为被明确记录的失败样例。

- Conflict review：对可能不一致的证据进行标记与复核的过程。

- Blind spot：当前实现或评估没有覆盖到的情况。

04 · 我的记录

- 哪个看起来很自然的问题最可能绕过我的拒答规则?

- 没有告警时，我还需要人工检查哪些证据关系?

忙碌日：20分钟

- 用5分钟阅读第一个概念，写出本课要解决的问题。

- 用10分钟运行 python run.py day 29，打开 outputs/day29.json，检查一个关键字段。

- 用5分钟完成第一道自测并留一句解释，完整实验与验收留到下次。

保存一份运行结果和自己的解释；精简练习单独记录，不等于整课验收全部完成。

有余力再做：20分钟选学 · 把本课机制迁移到一个自己的任务

- 从自己的文献整理或数据分析流程中选一个相似环节。

- 写清输入、允许动作、失败出口与验收方法。

- 提出一个会让当前实现失败的反例，并标明它是待实现扩展。

参考资料与阅读范围

BioAgentLab：科研 Agent 教材：阅读 book/zh/31_benchmark_and_failure_cases.md，按未知、冲突、工具错误和攻击分类记录。

https://github.com/zbyloveyj/BioAgentLab

OWASP：Prompt Injection：对照攻击测试和防护局限，区分规则演示与真实模型评估。

https://genai.owasp.org/llmrisk/llm01-prompt-injection/

下一步

最后一课完成可复现演示、能力卡与下一阶段学习计划。